

競馬予測システム 設計書

複勝期待値分析モデル

1. 概要

本システムはJRA 平地レースを対象に、複勝（3着以内）の期待値を算出し、長期的な回収率プラスを目指す予測モデルです。

分析対象

項目	内容
対象	JRA（中央競馬）のみ
レース種別	平地レース（芝・ダート）のみ
除外	障害レース
予測ターゲット	複勝（3着以内に入るか：1 or 0）
最終目的	複勝オッズ × 予測勝率 による期待値算出

2. システム構成

ツール	用途	費用
Supabase	データ保存（PostgreSQL）	無料
Google Colab	過去データ一括取得	無料
GitHub Actions	直近データ定期取得（毎週自動）	無料
LightGBM	機械学習による勝率予測	無料
netkeiba.com	スクレイピング元	無料（個人利用）

データ取得戦略

用途	ツール	取得元	頻度
過去データ一括	Google Colab（手動）	db.netkeiba.com	1回のみ
直近データ定期	GitHub Actions（自動）	race.netkeiba.com	毎週土日

3. 特徴量設計

以下の特徴量を LightGBM モデルの入力として使用します。

【レース条件】

特徴量	内容	優先度
開催場所	東京・中山・京都・阪神など 10 場	高
距離	1000m～3600m	高
芝/ダート	芝 or ダート	高
馬場状態	良/稍重/重/不良	高
天気	晴/曇/雨/小雨	中
枠番	1～8 枠	中
出走頭数	頭数（多いほど難易度 UP）	中
クラス	G1/G2/G3/OP/条件戦など	高

【馬の過去成績】

特徴量	内容	優先度
過去 3 走の着順平均	直近 3 レースの平均着順	高
過去 5 走の複勝率	直近 5 レースで 3 着以内の割合	高
同距離での複勝率	同距離レースでの複勝率	高
同芝/ダートでの複勝率	同馬場種別での複勝率	高
同開催場所での複勝率	同会場での複勝率	中
前走着順	前走の着順	高
前走からの間隔（日数）	休養日数・連戦疲労の指標	中
前走との距離差	距離延長/短縮の指標	中
馬体重	出走時の馬体重（kg）	中
馬体重増減	前走比の馬体重変化	中

【騎手】

特徴量	内容	優先度
騎手の全体複勝率	全レースでの複勝率	高
騎手×距離の複勝率	距離別の複勝率	中
騎手×開催場所の複勝率	会場別の複勝率	中
騎手×馬場状態の複勝率	馬場状態別の複勝率	中

【調教師】

特徴量	内容	優先度
調教師の全体複勝率	全レースでの複勝率	中
調教師×距離の複勝率	距離別の複勝率	低

【血統】

特微量	内容	優先度
父の産駒複勝率	父（種牡馬）の産駒全体の複勝率	中
父×距離の複勝率	父の産駒の距離別複勝率	中
父×芝/ダートの複勝率	父の産駒の馬場種別複勝率	中
母父の産駒複勝率	母父（BMS）の産駒複勝率	低

【オッズ・人気】

特微量	内容	優先度
単勝オッズ	市場が評価する勝率の逆数	高
人気順	1～出走頭数	高
相対的人気	人気順÷出走頭数（0～1 に正規化）	高

4. モデル構築計画

Step	内容	詳細
1	データ収集	2～3 年分のレースデータを Supabase に蓄積
2	特微量エンジニアリング	SQL ビューで集計値を算出（騎手勝率・馬の過去成績など）
3	モデル学習	LightGBM で複勝予測モデルを構築（Google Colab）
4	バックテスト	過去データで回収率を検証
5	期待値算出	予測勝率 × 複勝オッズ で期待値を算出
6	本番運用	毎週レース前に期待値プラスの馬を出力

5. 期待値算出式

期待値 = 予測複勝率 × 複勝オッズ

例：予測複勝率 40%、複勝オッズ 3.0 倍

$0.40 \times 3.0 = 1.2 \rightarrow$ 期待値プラス（買い）

期待値 > 1.0 の馬のみ購入することで、長期的な回収率プラスを目指します。

6. 懸念点・注意事項

- データ量：最低 2～3 年分（約 14,000 レース以上）必要
- 過学習：バックテストの精度に過度に依存しない
- オッズ変動：直前オッズと予測時点のオッズが異なる場合がある

- 競馬は確率ゲーム：回収率 100%超えを保証するものではない
- スクレイピング：netkeiba の利用規約に注意（個人・非商用利用）

作成日：2026/5/22