

特徴量エンジニアリング設計書

競馬予測システム SQL ビュー・集計ロジック定義

1. 概要

生データ（races・race_entries 等）から機械学習モデルの入力となる特徴量を算出します。特徴量は SQL の VIEW として定義し、モデル学習時に Colab から参照します。

2. 特徴量一覧

2-1. レース条件（固定情報）

races テーブルから直接取得できる情報です。加工不要です。

特徴量名	型	算出方法	優先度
venue_code	VARCHAR	races.venue_code そのまま	高
distance	INT	races.distance そのまま	高
surface	VARCHAR	races.surface（芝/ダート）	高
track_condition	VARCHAR	races.track_condition（良/稍重/重/不良）	高
weather	VARCHAR	races.weather（晴/曇/雨）	中
post_position	INT	race_entries.post_position（枠番 1~8）	中
entry_count	INT	同 race_id の出走頭数を COUNT で集計	中
class	VARCHAR	races.class（G1/G2/G3/OP/条件戦など）	高

2-2. 馬の過去成績（集計値）

race_entries を自己結合し、対象レースより過去のデータのみで集計します。

特徴量名	型	算出方法	優先度
horse_avg_finish_3	FLOAT	過去 3 走の着順平均（同馬・同 race_date より前）	高
horse_avg_finish_5	FLOAT	過去 5 走の着順平均	高
horse_fukusho_rate_3	FLOAT	過去 3 走の複勝率（3 着以内/出走数）	高
horse_fukusho_rate_5	FLOAT	過去 5 走の複勝率	高
horse_fukusho_distance	FLOAT	同距離±200m 以内での複勝率（全期間）	高
horse_fukusho_surface	FLOAT	同芝/ダートでの複勝率（全期間）	高
horse_fukusho_venue	FLOAT	同開催場所での複勝率（全期間）	中

horse_last_finish	INT	前走の着順	高
horse_rest_days	INT	前走からの間隔（日数）	中
horse_distance_diff	INT	前走との距離差（プラス=距離延長）	中
horse_weight	INT	race_entries.weight（馬体重 kg）	中
horse_weight_diff	INT	race_entries.weight_diff（前走比増減）	中

2-3. 騎手（集計値）

対象レース以前のデータで騎手の成績を集計します。

特徴量名	型	算出方法	優先度
jockey_fukusho_rate	FLOAT	騎手の全体複勝率（全期間・全コース）	高
jockey_fukusho_distance	FLOAT	騎手×距離±200m 以内の複勝率	中
jockey_fukusho_venue	FLOAT	騎手×開催場所の複勝率	中
jockey_fukusho_surface	FLOAT	騎手×芝/ダートの複勝率	中
jockey_fukusho_condition	FLOAT	騎手×馬場状態の複勝率	中

2-4. 調教師（集計値）

特徴量名	型	算出方法	優先度
trainer_fukusho_rate	FLOAT	調教師の全体複勝率（全期間）	中
trainer_fukusho_distance	FLOAT	調教師×距離±200m 以内の複勝率	低

2-5. 血統（集計値）

horse_pedigrees と race_entries を結合し、父・母父の産駒成績を集計します。

特徴量名	型	算出方法	優先度
father_fukusho_rate	FLOAT	父（種牡馬）の産駒全体の複勝率	中
father_fukusho_distance	FLOAT	父の産駒×距離±200m 以内の複勝率	中
father_fukusho_surface	FLOAT	父の産駒×芝/ダートの複勝率	中
mother_father_fukusho_rate	FLOAT	母父（BMS）の産駒全体の複勝率	低

2-6. オッズ・人気

特徴量名	型	算出方法	優先度
odds	FLOAT	race_entries.odds (単勝オッズ)	高
popularity	INT	race_entries.popularity (人気順)	高
popularity_ratio	FLOAT	人気順 ÷ 出走頭数 (0~1 に正規化)	高

3. SQL ビュー定義

3-1. 騎手複勝率ビュー (v_jockey_stats)

```
CREATE OR REPLACE VIEW v_jockey_stats AS
SELECT
  e.jockey_id,
  r.venue_code,
  r.surface,
  r.track_condition,
  ROUND(AVG(CASE WHEN e.finish_position <= 3 THEN 1.0 ELSE 0.0 END), 4) AS
fukusho_rate,
  COUNT(*) AS total_races
FROM race_entries e
JOIN races r ON e.race_id = r.race_id
WHERE e.finish_position IS NOT NULL
GROUP BY e.jockey_id, r.venue_code, r.surface, r.track_condition;
```

3-2. 父産駒複勝率ビュー (v_father_stats)

```
CREATE OR REPLACE VIEW v_father_stats AS
SELECT
  p.father,
  r.surface,
  r.distance,
  ROUND(AVG(CASE WHEN e.finish_position <= 3 THEN 1.0 ELSE 0.0 END), 4) AS
fukusho_rate,
  COUNT(*) AS total_races
FROM race_entries e
JOIN races r ON e.race_id = r.race_id
JOIN horse_pedigrees p ON e.horse_id = p.horse_id
WHERE e.finish_position IS NOT NULL
GROUP BY p.father, r.surface, r.distance;
```

4. 注意事項

- データリーク防止: 特徴量の集計は必ず「対象レース開催日より前」のデータのみを使用する

- サンプル数が少ない場合（10 件未満）は集計値を NULL として扱い、モデル側で補完する
- 障害レースのデータは除外（surface = '障害' を除く）
- 最低データ量：2～3 年分（約 14,000 レース）以上が揃ってからモデル学習を開始する

作成日：2026/5/22