

競馬予測システム 設計書

複勝期待値分析モデル

1. 概要

本システムは JRA 平地レースを対象に、複勝（3 着以内）の期待値を算出し、長期的な回収率プラスを目指す予測モデルです。

分析対象

項目	内容
対象	JRA（中央競馬）のみ
レース種別	平地レース（芝・ダート）のみ
除外	障害レース
予測ターゲット	複勝（3 着以内に入るか：1 or 0）
最終目的	複勝オッズ × 予測勝率 による期待値算出

2. システム構成

ツール	用途	費用
Supabase	データ保存（PostgreSQL）	無料
Google Colab	過去データ一括取得・直近データ取得（両方）	無料
LightGBM	機械学習による勝率予測	無料
db.netkeiba.com	スクレイピング元（全データ）	無料（個人利用）

データ取得戦略

※ race.netkeiba.com のレース一覧は 2026 年 4 月をもってサービス終了のため、全データを db.netkeiba.com から取得する。

用途	ツール	取得元	頻度
過去データ一括	Google Colab（手動）	db.netkeiba.com	1 回のみ
直近データ取得	Google Colab（手動）	db.netkeiba.com	週 1 回程度

3. 特徴量設計

以下の特徴量を LightGBM モデルの入力として使用します。

【レース条件】

特徴量	内容	優先度
開催場所	東京・中山・京都・阪神など 10 場	高
距離	1000m～3600m	高
芝/ダート	芝 or ダート	高
馬場状態	良/稍重/重/不良	高
天気	晴/曇/雨/小雨	中
枠番	1～8 枠	中
出走頭数	頭数（多いほど難易度 UP）	中
クラス	G1/G2/G3/OP/条件戦など	高

【馬の過去成績】

特徴量	内容	優先度
過去 3 走の着順平均	直近 3 レースの平均着順	高
過去 5 走の複勝率	直近 5 レースで 3 着以内の割合	高
同距離での複勝率	同距離レースでの複勝率	高
同芝/ダートでの複勝率	同馬場種別での複勝率	高
同開催場所での複勝率	同会場での複勝率	中
前走着順	前走の着順	高
前走からの間隔（日数）	休養日数・連戦疲労の指標	中
前走との距離差	距離延長/短縮の指標	中
馬体重	出走時の馬体重（kg）	中
馬体重増減	前走比の馬体重変化	中

【騎手】

特徴量	内容	優先度
騎手の全体複勝率	全レースでの複勝率	高
騎手×距離の複勝率	距離別の複勝率	中
騎手×開催場所の複勝率	会場別の複勝率	中
騎手×馬場状態の複勝率	馬場状態別の複勝率	中

【調教師】

特徴量	内容	優先度
調教師の全体複勝率	全レースでの複勝率	中
調教師×距離の複勝率	距離別の複勝率	低

【血統】

特徴量	内容	優先度
父の産駒複勝率	父（種牡馬）の産駒全体の複勝率	中
父×距離の複勝率	父の産駒の距離別複勝率	中
父×芝/ダートの複勝率	父の産駒の馬場種別複勝率	中
母父の産駒複勝率	母父（BMS）の産駒複勝率	低

【オッズ・人気】

特徴量	内容	優先度
単勝オッズ	市場が評価する勝率の逆数	高
人気順	1～出走頭数	高
相対的人気	人気順÷出走頭数（0～1 に正規化）	高

4. モデル構築計画

Step	内容	詳細
1	データ収集	2～3年分のレースデータを Supabase に蓄積
2	特徴量エンジニアリング	SQL ビューで集計値を算出（騎手勝率・馬の過去成績など）
3	モデル学習	LightGBM で複勝予測モデルを構築（Google Colab）
4	バックテスト	過去データで回収率を検証
5	期待値算出	予測勝率 × 複勝オッズ で期待値を算出
6	本番運用	毎週レース前に期待値プラスの馬を出力

5. 期待値算出式

期待値 = 予測複勝率 × 複勝オッズ

例：予測複勝率 40%、複勝オッズ 3.0 倍

$0.40 \times 3.0 = 1.2 \rightarrow$ 期待値プラス（買い）

期待値 > 1.0 の馬のみ購入することで、長期的な回収率プラスを目指します。

6. 懸念点・注意事項

- データ量：最低 2～3 年分（約 14,000 レース以上）必要
- 過学習：バックテストの精度に過度に依存しない
- オッズ変動：直前オッズと予測時点のオッズが異なる場合がある
- 競馬は確率ゲーム：回収率 100%超えを保証するものではない
- スクレイピング：netkeiba の利用規約に注意（個人・非商用利用）

作成日：2026/5/22