

モデル設計書

LightGBM 複勝予測モデル

1. モデル概要

項目	内容
アルゴリズム	LightGBM (勾配ブースティング決定木)
予測タスク	2 値分類 (複勝: 3 着以内=1、それ以外=0)
出力	複勝確率 (0~1)
期待値算出	予測複勝率 × 複勝オッズ
購入基準	期待値 > 1.0 の馬のみ
学習環境	Google Colab (Python 3)
必要データ量	最低 2~3 年分 (約 14,000 レース・約 200,000 行)

2. LightGBM パラメータ

以下を初期値とし、バックテスト結果に応じて調整します。

パラメータ	初期値	説明
objective	binary	2 値分類タスク
metric	auc	評価指標: AUC (ROC 曲線下面積)
num_leaves	31	1 ツリーの葉の数 (複雑さの調整)
learning_rate	0.05	学習率 (小さいほど安定)
n_estimators	1000	ブースティング回数 (early_stopping で調整)
min_child_samples	20	葉の最小サンプル数 (過学習防止)
feature_fraction	0.8	各ツリーで使う特徴量の割合
bagging_fraction	0.8	各ツリーで使うデータの割合
early_stopping_rounds	50	改善がなければ学習を早期終了
class_weight	balanced	複勝/非複勝のクラス不均衡を補正

3. 学習・評価手順

3-1. データ分割

時系列データのため、ランダム分割ではなく時系列分割を使用します。

データセット	期間（目安）	用途
学習データ	～直近2年前まで	モデルの学習に使用
検証データ	直近2年～1年前	early_stopping・パラメータ調整
テストデータ	直近1年分	最終評価・バックテスト

3-2. Colabでの学習コード（概要）

```
import lightgbm as lgb
from sklearn.model_selection import train_test_split

# 特徴量とターゲットを分離
X = df.drop(['target', 'race_id', 'race_date'], axis=1)
y = df['target'] # 3着以内=1, それ以外=0

# 時系列分割
train = df[df['race_date'] < '2025-01-01']
valid = df[(df['race_date'] >= '2025-01-01') & (df['race_date'] < '2026-01-01')]
test = df[df['race_date'] >= '2026-01-01']

# モデル学習
model = lgb.LGBMClassifier(**params)
model.fit(X_train, y_train,
          eval_set=[(X_valid, y_valid)],
          callbacks=[lgb.early_stopping(50)])

# 複勝確率予測
proba = model.predict_proba(X_test)[: , 1]

# 期待値算出
df_test['predicted_proba'] = proba
df_test['expected_value'] = proba * df_test['fukusho_odds']
```

4. 評価指標

指標	目標値	説明
AUC	0.65 以上	複勝予測の識別能力（1.0 が完璧）
回収率	100%以上	期待値>1.0 の馬のみ購入した場合の回収率
的中率	参考値	的中率より回収率を優先する
購入対象数	全体の 20～30%	期待値>1.0 の馬の割合（多すぎは過剰フィルタ）

5. 特徴量重要度

学習後に LightGBM の feature_importance を確認し、寄与度の低い特徴量は削除します。

```
lgb.plot_importance(model, max_num_features=20)
```

6. モデルの保存・更新

項目	内容
保存形式	pickle または joblib (.pkl)
保存場所	Google Drive (Colab からアクセス可能)
更新頻度	データが3ヶ月以上増えたら再学習
バージョン管理	ファイル名に日付を付与 (例: model_20260601.pkl)

作成日: 2026/5/22